

Experimentación en DES

Parcial 3. Modelación y Simulación 5

Manuela Valencia¹, Sara María Cano² y Thomas Martinod³

¹Ingeniería Matemática, Universidad EAFIT, Medellín, Colombia,
mvalenciaf@eafit.edu.co

²Ingeniería Matemática, Universidad EAFIT, Medellín, Colombia,
smcanom@eafit.edu.co

³Ingeniería Matemática, Universidad EAFIT, Medellín, Colombia,
tmartinods@eafit.edu.co

Resumen

El siguiente escrito expone la solución al tercer parcial del curso Modelación y Simulación 5 impartido en la Universidad EAFIT. El archivo `Simul8` y el código en R desarrollados (además de este documento) se albergan en el [repositorio del parcial](#).

1. El Problema

La planta de televisores opera de 7:00 a.m. a 7:00 p.m., de lunes a viernes. Durante la mañana, las órdenes de fabricación de televisores ingresan cada 15 minutos, mientras que por la tarde ingresan cada 20 minutos. La distribución de órdenes es 40 % LED, 35 % Smart TV y 25 % 4K.

Hay tres líneas de ensamblaje, cada una especializada para un tipo de televisor, con tiempos de procesamiento normales de 30, 35 y 40 minutos, respectivamente. Después del ensamblaje, los televisores se organizan en una cola de inspección por prioridad (4K, Smart TV, LED), con tiempos de inspección de 20 minutos para Smart TV y 4K, y 15 minutos para LED.

La planta experimenta paros no programados con una media de 120 minutos entre cada paro, y una duración de reparación de 10 a 30 minutos, realizada por técnicos.

En cuanto al personal, hay 3 operarios de ensamblaje en la mañana y 2 en la tarde, 2 operarios de inspección todo el día, y 2 técnicos de reparación en la mañana y 1 en la tarde.

El objetivo es simular una semana de trabajo, acumulando la producción no terminada para el siguiente día.

El jefe de la fábrica quiere cumplir los siguientes objetivos:

- Objetivos de Tiempo:
 - El tiempo promedio en el sistema no debe superar 1.5 horas para el 85 % de los productos terminados.

- Ningún producto debe permanecer en el sistema más de 5 horas.
- Eficiencia del Personal:
 - Los operarios de inspección y ensamble deben ser capaces de desempeñar cualquiera de las dos labores.
 - El supervisor desea que ambos operarios trabajen al menos el 85 % del tiempo y, como máximo, el 95 % del tiempo.

La convención a usar durante el parcial, para las variables de interés será:

Variable	Convención
Número de Operarios de Inspección	<i>OI</i>
Número de Operarios de Ensamble	<i>OE</i>
Número de réplicas ensamblaje LED	<i>RLED</i>
Número de réplicas ensamblaje Smart TV	<i>RSTV</i>
Número de réplicas ensamblaje 4K	<i>R4K</i>
Número de réplicas inspección	<i>RI</i>

Cuadro 1: Convención de variables

2. Evaluación de Alternativas

En esta sección, se prueban varias alternativas de solución para cumplir con los objetivos. Se probaron 6 escenarios, donde se cambiaban el número de operarios de ensamblaje y de inspección, el número de estaciones disponible para cada actividad (Replicate) y se registraron los resultados. Además, para cada escenario se hicieron 25 corridas. Los escenarios fueron los siguientes:

Escenario	OE	OI	T	RSTV	RLED	R4K	RIN
1	2	2	1	1	1	1	2
2	1	2	1	1	1	1	2
3	2	1	1	2	1	1	2
4	2	2	1	2	2	2	2
5	2	2	1	3	3	3	2
6	4	3	1	3	3	3	2

Cuadro 2: Datos de los escenarios

Los resultados obtenidos se observan en la figura 1.

En estos 6 experimentos, solo en el caso 6 se cumple el objetivo de que tiempo promedio sea menor a 1.5 horas y que ningún producto permanece en el sistema más de 5 horas. Sin embargo, en este caso no se cumplieron los objetivos de eficiencia del personal ya que todos los operarios tienen un porcentaje de ocupación menor al 85 %. En los escenarios 2 y 3 sí se cumplen los porcentajes de ocupación pero los tiempos en el sistema superan las 5 horas.

Por lo tanto, la solución que se propone para cumplir los objetivos del tiempo es contratar 4 operadores de ensamblaje y 3 de inspección pero se sacrifica la eficiencia de estos. Si el jefe, le da más prioridad a la eficiencia, puede contratar 2 operarios de cada tipo.

	Base Run					
	Trial_5 Average	Trial_6 Average	Trial_4 Average	Trial_3 Average	Trial_2 Average	Trial_1 Average
Llegada de órdenes.Number Entered	202.48	202.48	202.48	202.48	202.48	202.48
Cola LED.Average Queuing Time	22.16229	3.81041	25.88336	294.83574	294.83574	88.86948
Cola Smart TV.Average Queuing Time	22.84934	4.42014	29.20604	285.59965	285.59965	108.91138
Cola 4K.Average Queuing Time	16.6292	3.14939	18.85572	137.11616	137.11616	58.11454
Cola Inspección.Average Queuing Time	59.99638	6.66121	50.51616	55.93173	55.93173	5.84034
Productos terminados.Number Completed	195.8	199.48	196.24	170.28	170.28	193.64
Productos terminados.Average Time in System	144.21845	74.34884	139.55031	357.94333	357.94333	159.25889
Productos terminados.Average Time in System (1)	195.23155	70.15573	183.31054	452.22078	452.22078	151.89356
Productos terminados.Maximum Time in System (1)	568.4596	168.45407	524.16645	877.5709	877.5709	338.9636
Productos terminados.Average Time in System (2)	121.88803	75.85735	120.11121	367.27704	367.27704	179.3633
Productos terminados.Maximum Time in System (2)	279.41982	140.53217	279.97036	694.43799	694.43799	377.9893
Productos terminados.Average Time in System (3)	99.48874	78.69254	100.32197	221.43409	221.43409	134.94141
Productos terminados.Maximum Time in System (3)	179.54436	137.77363	184.27553	456.47489	456.47489	294.81252
Op_Ensamble.Utilization %	88.99128	66.34944	88.93846	97.61838	98.10761	91.32168
Op_Inspección.Utilization %	74.68869	22.25668	75.35303	94.28618	95.70766	69.9915
Técnicos_reparación.Utilization %	40.84065	40.84065	40.84065	40.84065	40.84065	40.84065
Productos terminados.% In System Less Than Time Limit	42.67302	77.97443	42.20565	8.59041	8.59041	28.84819
Productos terminados.Maximum Time in System	568.4596	176.67584	524.21235	982.66934	982.66934	434.41263

Figura 1: Resultados

3. Diseño de Experimentos 2^k

En esta sección se propone un diseño de experimentos factorial completo 2^k para evaluar el impacto de diferentes configuraciones en los objetivos de desempeño de la planta. Los factores experimentales a considerar son dos:

- Número de operarios: Incluye operarios de dos tipos (ensamble y inspección).
- Numero de Actividades: Considera las réplicas de las actividades asociadas con cada operación dentro de la planta.

Como nota, para todo este punto, los análisis se harán sobre el primer objetivo **el tiempo promedio en el sistema** y se evaluará si se cumple el segundo objetivo (porcentaje de ocupación) como **consecuencia** y no como variable de decisión. Los análisis se pueden hacer para ambos indicadores de desempeño, pero como hay un objetivo principal claro, por simplicidad se considera solo el tiempo en el sistema.

Se separa esta sección en subsecciones como se propone en el parcial.

3.1. Factores y Análisis de Varianza

En el diseño de experimentos 2^k , se cuenta con k variables que pueden estar en 2 estados. En particular, se considerarán todas las variables del cuadro 1. Con respecto a los estados posibles, para cada variable hay un estado titulado como “−” y un estado titulado como “+”, que representan el estado usual, default o basal de la cantidad y la alternativa a evaluar (por lo general mayor), respectivamente.

Los estados de las variables a evaluar se muestran en el cuadro 3.1.

Variable	−	+
OI	2	4
OE	2	4
RLED	1	2
RSTV	1	2
R4K	1	2
RI	1	2

Cuadro 3: Estados de las $k = 6$ variables.

Ahora, ¿Qué es el análisis de varianza? El análisis de varianza (ANOVA) es una técnica estadística empleada para comparar las medias de tres o más grupos. La hipótesis nula (H_0) postula que no existen diferencias significativas entre las medias de los grupos ($\mu_1 = \mu_2 = \dots = \mu_k$), mientras que la hipótesis alternativa (H_1) indica que al menos una de las medias es significativamente distinta de las demás.

El ANOVA evalúa esta disparidad mediante la comparación de la variabilidad entre grupos y la variabilidad dentro de los grupos. Lo más vital de todo es que el análisis calcula un estadístico F que permite calcular el valor p del test.

El valor p , es la probabilidad de obtener un valor de la estadística F al menos tan extremo como el observado, asumiendo que la hipótesis nula es verdadera. En este contexto, el valor P es una medida de la significancia estadística del efecto observado. Si el valor p es menor que un nivel de significancia predefinido (tomaremos $\alpha = 0,05$), se rechaza la hipótesis nula, lo que sugiere que al menos una de las medias es significativamente diferente de las demás. Por el contrario, si el valor p es mayor que el nivel de significancia, no hay suficiente evidencia para rechazar la hipótesis nula y se concluye que no hay diferencias significativas entre las medias de los grupos.

Ahora, para el análisis de varianza (y el resto de este punto) se hizo un script en R, ubicado en el [repositorio del parcial](#). Los resultados del análisis de varianza fueron se enseñan en la figura 2.

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
OE	1	9384	9384	341.238	6.96e-15 ***
OI	1	9384	9384	341.238	6.96e-15 ***
R4K	1	179	179	6.524	0.018083 *
RLED	1	2089	2089	75.968	1.38e-08 ***
RSTV	1	658	658	23.917	6.87e-05 ***
RI	1	329163	329163	11969.039	< 2e-16 ***
OE:OI	1	8668	8668	315.195	1.58e-14 ***
OE:R4K	1	343	343	12.485	0.001868 **
OE:RLED	1	429	429	15.608	0.000680 ***
OE:RSTV	1	659	659	23.955	6.81e-05 ***
OE:RI	1	177	177	6.443	0.018731 *
OI:R4K	1	343	343	12.485	0.001868 **
OI:RLED	1	429	429	15.608	0.000680 ***
OI:RSTV	1	659	659	23.955	6.81e-05 ***
OI:RI	1	177	177	6.443	0.018731 *
R4K:RLED	1	0	0	0.001	0.982274
R4K:RSTV	1	0	0	0.009	0.926935
R4K:RI	1	340	340	12.361	0.001948 **
RLED:RSTV	1	9	9	0.330	0.571647
RLED:RI	1	1849	1849	67.247	3.91e-08 ***
RSTV:RI	1	4479	4479	162.852	1.21e-11 ***
OE:OI:R4K	1	240	240	8.739	0.007297 **
OE:OI:RLED	1	302	302	10.973	0.003166 **
OE:OI:RSTV	1	497	497	18.062	0.000328 ***
OE:OI:RI	1	148	148	5.398	0.029799 *
OE:R4K:RLED	1	2	2	0.072	0.790298
OE:R4K:RSTV	1	67	67	2.454	0.131487
OE:R4K:RI	1	13	13	0.469	0.500432
OE:RLED:RSTV	1	8	8	0.306	0.585699
OE:RLED:RI	1	109	109	3.958	0.059211 .
OE:RSTV:RI	1	36	36	1.314	0.264008
OI:R4K:RLED	1	2	2	0.072	0.790298
OI:R4K:RSTV	1	67	67	2.454	0.131487
OI:R4K:RI	1	13	13	0.469	0.500432
OI:RLED:RSTV	1	8	8	0.306	0.585699
OI:RLED:RI	1	109	109	3.958	0.059211 .
OI:RSTV:RI	1	36	36	1.314	0.264008
R4K:RLED:RSTV	1	10	10	0.376	0.546128
R4K:RLED:RI	1	2	2	0.082	0.777479
R4K:RSTV:RI	1	8	8	0.305	0.586387
RLED:RSTV:RI	1	2	2	0.081	0.779165
Residuals	22	605	28		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					

Figura 2: Análisis de Varianza en R.

En síntesis, el análisis lo que hace es fijar un valor de la o las variables que aparecen a la izquierda (se hizo hasta 3 el análisis por su longitud). De las combinaciones restantes se saca una media de la variable \bar{t}_{sis} , el tiempo promedio en el sistema. Se hallan las varianzas, los residuos, las desviaciones

de estos, el estadístico F y en última columna numérica se calcula el valor p .

La notación de asteriscos y puntos de la última columna es lo más fácil de interpretar (son órdenes de magnitud). Se rechaza la hipótesis nula H_0 para aquellos valores p con magnitudes menores a 0.05, es decir, aquellas combinaciones en las que se obtuvieron uno, dos o tres asteriscos.

Es fácil ver que para todas las variables individuales y todos los pares de variables se rechaza esta hipótesis, es decir, al fijarlas, al menos una de las medias de \bar{t}_{sis} es diferente a las demás, por lo que **todas** las combinaciones son significativas (no se puede descartar ninguna variable). Con tres o más variables fijas, algunos valores p son mayores a α , luego no se rechaza H_0 . Esto es de esperarse puesto que se reducen las combinaciones posibles en las variables restantes y es más probable que las medias de \bar{t}_{sis} se asemejen mucho.

Por último, aunque no fue requerido en el enunciado, se hizo el test de Shapiro-Wilk para evaluar la normalidad de la renormalización del modelo de regresión lineal usado en el ANOVA. En las figuras 3 y 4 se observan los resultados (para agrupaciones en triplas).




Figura 3: Gráfico cuantil cuantil.

```
Shapiro-Wilk normality test
data:  rstandard(Model)
W = 0.97481, p-value = 0.2142
```

Figura 4: Resultados test de Shapiro Wilk.

Exhiben un muy buen comportamiento normal los residuos de la regresión lineal del problema.

3.2. Prueba de Comparaciones Múltiples

La prueba de comparaciones múltiples de Tukey (TukeyHSD en R) es una técnica utilizada para realizar comparaciones entre pares de medias de grupos después de haber realizado un análisis de varianza (ANOVA). Esta prueba controla el error experimental (la probabilidad de cometer un error de tipo I) al realizar múltiples comparaciones.

Básicamente, la prueba de Tukey compara todas las combinaciones posibles de pares de medias de grupos y calcula intervalos de confianza para las diferencias entre estas medias. Si la diferencia entre dos medias cae dentro del intervalo de confianza correspondiente, se concluye que no hay una diferencia significativa entre esas medias. Por otro lado, si la diferencia cae fuera del intervalo de confianza, se considera que hay una diferencia significativa entre las medias de esos dos grupos.

Ahora bien, esta prueba también se hace sobre todas las combinaciones del ANOVA, por lo que es supremamente extensiva. Se enseña en la figura 5 el análisis para la tripla de mayor interés (OI, OE, RI).

`\$`OE:OI:RI`				
	diff	lwr	upr	p adj
4:2:1-2:2:1	-5.386789e+01	-62.622287	-45.113491	0.0000000
2:4:1-2:2:1	-5.386789e+01	-62.622287	-45.113491	0.0000000
4:4:1-2:2:1	-5.509212e+01	-63.846522	-46.337726	0.0000000
2:2:2-2:2:1	-1.531332e+02	-161.887565	-144.378770	0.0000000
4:2:2-2:2:1	-1.942537e+02	-203.008058	-185.499262	0.0000000
2:4:2-2:2:1	-1.942537e+02	-203.008058	-185.499262	0.0000000
4:4:2-2:2:1	-1.949144e+02	-203.668809	-186.160013	0.0000000
2:4:1-4:2:1	2.842171e-14	-8.754398	8.754398	1.0000000
4:4:1-4:2:1	-1.224235e+00	-9.978633	7.530163	0.9997080
2:2:2-4:2:1	-9.926528e+01	-108.019677	-90.510881	0.0000000
4:2:2-4:2:1	-1.403858e+02	-149.140169	-131.631373	0.0000000
2:4:2-4:2:1	-1.403858e+02	-149.140169	-131.631373	0.0000000
4:4:2-4:2:1	-1.410465e+02	-149.800920	-132.292125	0.0000000
4:4:1-2:4:1	-1.224235e+00	-9.978633	7.530163	0.9997080
2:2:2-2:4:1	-9.926528e+01	-108.019677	-90.510881	0.0000000
4:2:2-2:4:1	-1.403858e+02	-149.140169	-131.631373	0.0000000
2:4:2-2:4:1	-1.403858e+02	-149.140169	-131.631373	0.0000000
4:4:2-2:4:1	-1.410465e+02	-149.800920	-132.292125	0.0000000
2:2:2-4:4:1	-9.804104e+01	-106.795442	-89.286646	0.0000000
4:2:2-4:4:1	-1.391615e+02	-147.915934	-130.407138	0.0000000
2:4:2-4:4:1	-1.391615e+02	-147.915934	-130.407138	0.0000000
4:4:2-4:4:1	-1.398223e+02	-148.576685	-131.067890	0.0000000
4:2:2-2:2:2	-4.112049e+01	-49.874890	-32.366095	0.0000000
2:4:2-2:2:2	-4.112049e+01	-49.874890	-32.366095	0.0000000
4:4:2-2:2:2	-4.178124e+01	-50.535642	-33.026846	0.0000000
2:4:2-4:2:2	1.421085e-14	-8.754398	8.754398	1.0000000
4:4:2-4:2:2	-6.607512e-01	-9.415149	8.093647	0.9999955
4:4:2-2:4:2	-6.607512e-01	-9.415149	8.093647	0.9999955

Figura 5: Prueba de comparaciones múltiples para OI, OE, RI.

Las columnas de resultados son:

- **diff**: La diferencia entre las medias de las combinaciones de niveles de las variables OI, OE y RI.
- **lwr**: El límite inferior del intervalo de confianza para la diferencia entre las medias.
- **upr**: El límite superior del intervalo de confianza para la diferencia entre las medias.
- **p adj**: El valor p ajustado para cada comparación, que indica la significancia estadística de la diferencia entre las medias.

Simplemente, se interpreta esta prueba de comparaciones múltiples con el valor p , de forma similar al ANOVA. Si el valor p es menor que un umbral predefinido (0.05), se considera que la diferencia entre los grupos es estadísticamente significativa, lo que sugiere que al menos uno de los grupos es significativamente diferente de los demás. Por otro lado, si el valor p es mayor que el umbral, no hay evidencia suficiente para rechazar la hipótesis nula de que no hay diferencias significativas entre los grupos comparados.

Notemos que los resultados anteriores solo arrojan $p \rightarrow 0.01$, lo que indica que el caso de estudio es sumamente sensible a algunos cambios de triplas (OI, OE, RI). Por ejemplo, pasar de (4,4,1) a (2,4,1) arroja un valor p cercano a 1. H_0 no se rechaza y el tiempo en el sistema no varía significativamente en la transición de esas tupla.

3.3. Boxplots

Los boxplots son mucho más sencillos de interpretar que el resto de diagramas que presentaremos. Para ellos, se toma el nivel $+$ o $-$ de una variable en particular, y se grafican en paralelo los diagramas de bigotes para la variable tiempo en el sistema en ambos casos.

Tenemos $k = 6$ boxplots, y se enseñarán solamente dos por cuestiones de longitud. En la figura 6 se muestran los diagramas de cajas para ambos niveles de la variable OE, mientras que en la figura 7 se muestran los mismos diagramas para la variable RSTV.

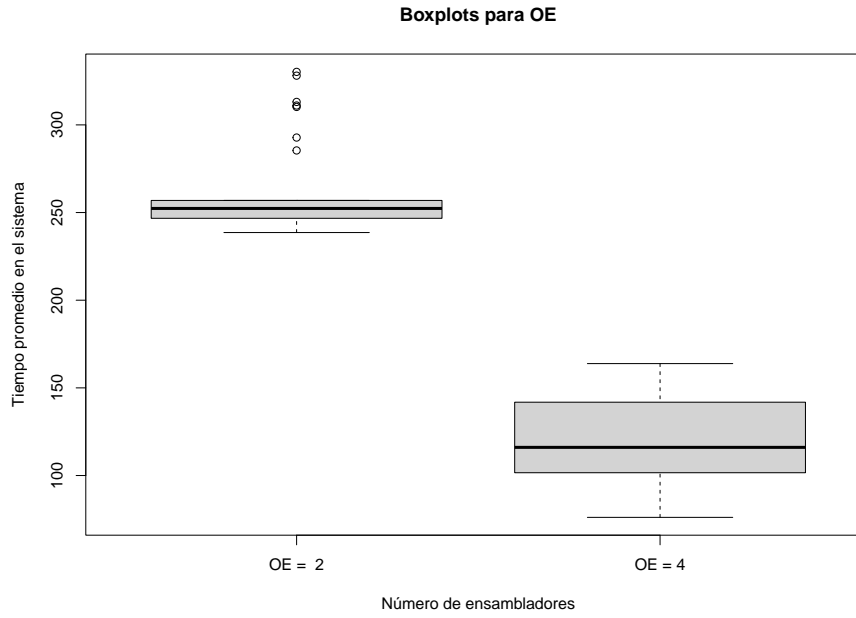


Figura 6: Boxplot \bar{t}_{sis} vs OE.

La interpretación es sencilla, cuando aumentamos de 2 a 4 el número de operarios, el tiempo promedio de los tiempos promedio del sistema disminuye significativamente. Aunque el rango intercuantil de las medidas aumente, la reducción del tiempo medio es tal que pasa a segundo plano, además que se hace un poco más robusto el sistema en cuanto a la inexistencia de outliers en $OE = 4$.

Por otro lado, cuando aumentamos la capacidad de ensambladores de televisores 4K (réplicas), vemos que el sistema permanece casi invariante.

A ojo ligero, las variables que (individualmente) causan un mayor impacto positivo en el tiempo en el sistema son OI, OE y RI (no en orden).

3.4. Gráficas de Efectos Principales

En general, una gráfica de efectos principales muestra la magnitud relativa de los efectos principales de cada factor en un diseño experimental. Cada eje de la gráfica representa un factor y la línea o barra que se muestra indica la magnitud del efecto principal para ese factor.

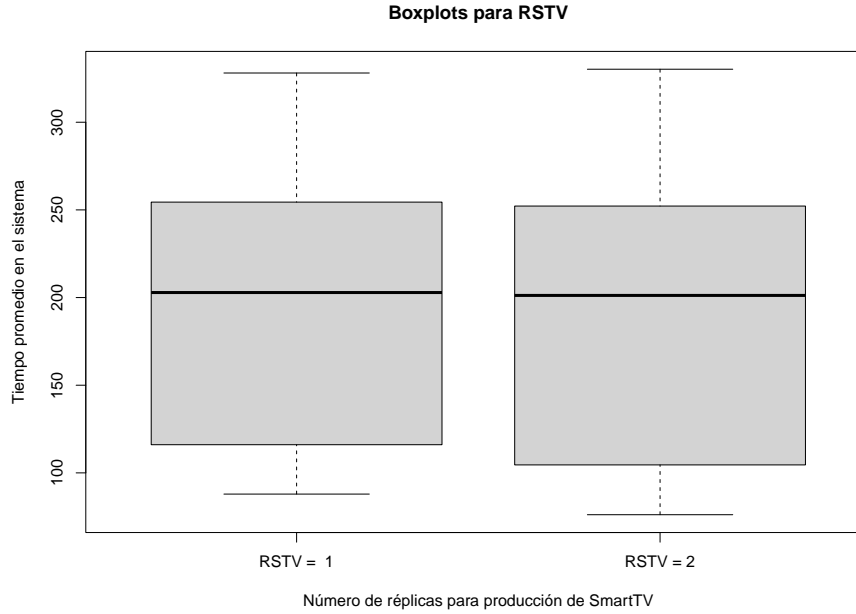


Figura 7: Boxplot \bar{t}_{sis} vs RSTV.

Estos gráficos permiten visualizar fácilmente qué factores tienen un mayor impacto en la variable de respuesta. Por ejemplo, si hay tres factores en un experimento, la gráfica de efectos principales mostrará tres líneas o barras, una para cada factor, y la **magnitud** de la pendiente de cada línea o barra será una medida empírica de lo *importante* que es la variable en el diseño del experimento.

En la figura 8, se expone la gráfica de efectos principales para las seis variables consideradas.

En particular, las rectas con mayor pendiente corresponden a las variables RI, OI y OE, y por lo tanto, estas tres variables son las más influyentes (de forma individual) a la hora de hallar el tiempo promedio en el sistema. Era fácil intuir de antemano esta mayor influencia, puesto que son aquellas variables que interactúan con todos los televisores en la simulación.

Recordemos que los dos tipos de operarios (OI y OE) pueden estar en las líneas de ensamblaje de cualquier televisor, por lo que una mayor disponibilidad de estos implica en general un menor tiempo en cola y un menor tiempo en el sistema. Por otra parte, cuando se ensamblan los televisores todos estos convergen a la misma fila de inspección, por lo que un mayor número de réplicas en este proceso claramente será un vital factor agilizador.

Por último, todas las pendientes tienen rectas negativas, indicando que conforme se aumente el número de recursos o réplicas, disminuye el tiempo promedio en el sistema.

3.5. Gráficas de Interacciones

En general, dos variables *independientes* interactúan si el efecto de una de las variables difiere según el nivel de la otra variable. Un gráfico de interacción muestra los niveles de una variable en el eje X y tiene una línea separada para las medias de cada nivel de la otra variable. El eje Y es la variable dependiente (en este caso es el tiempo promedio en el sistema).




Figura 8: Gráfica de efectos principales (tsis es el tiempo promedio en el sistema).

En la figura 9, se observan los $2^k - k$ gráficos de interacciones correspondientes a la cantidad de pares ordenados entre las 6 variables sin repetir.

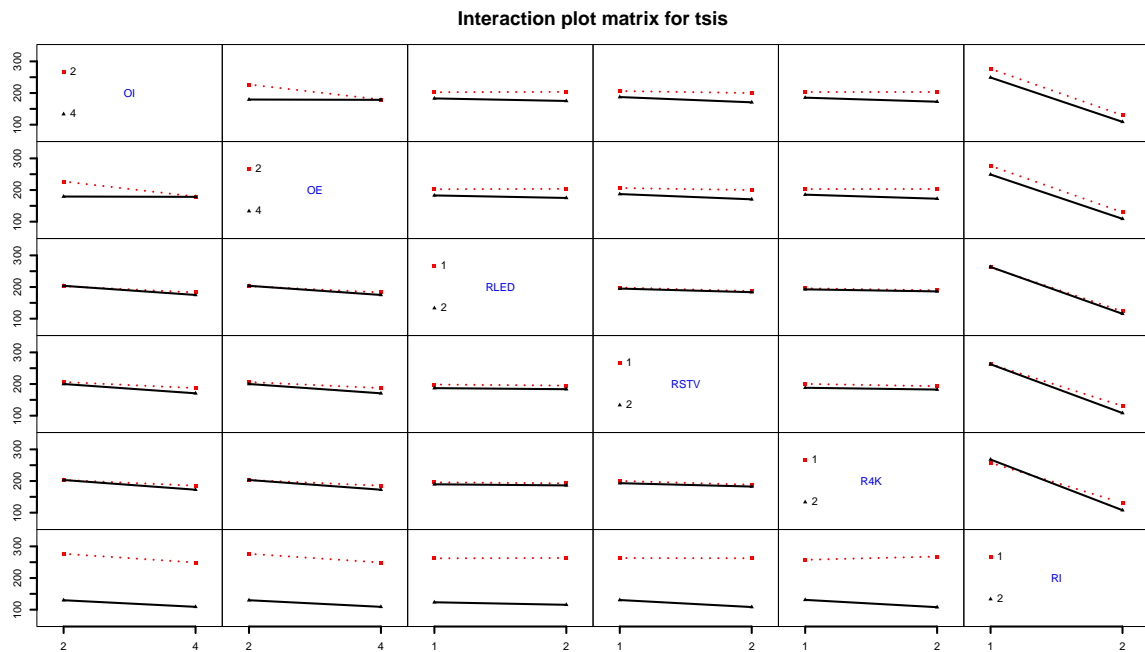


Figura 9: Gráfica de interacción por pares (tsis es el tiempo promedio en el sistema).

Lo más importante en la interpretación de estas gráficas es el grado de colinealidad de las rectas. Cuando dos rectas son paralelas, como por ejemplo se observa en las celdas (4,5) y (5,4), se concluye que las variables en cuestión no interactúan. En este caso es fácil ver que R4K y RSTV pueden modificarse libremente sin pensar en que le va a pasar a la otra variable.

Cuando no son colineales, pero el ángulo que forman es pequeño, como es el caso de las celdas (1,2) y (2,1), quiere decir que las variables interactúan levemente, y que a la hora de hacer el diseño de experimentos, cuando se aumente una de estas, se debe tener cuidado de como afecta a la otra variable. Por ejemplo, en la celda (1,2) se fijó la variable OE a sus niveles $-$ o $+$. A partir de ahí, la variable OI se varía de 2 a 4. Se puede notar que cuando $OE = 4$, el tiempo en el sistema no se inmuta cuando se varía OI (overkill de recursos), mientras que cuando $OE = 2$, el tiempo en el sistema si disminuye cuando OI aumenta.

Esta matriz de gráficas no ha de ser simétrica, en el caso anterior lo es porque en la simulación, los operarios de ensamblado e inspección hacen las mismas actividades. Finalmente, si en alguna subgráfica se hubiera visto un ángulo grande entre las rectas o una equis, diría que las variables son inversas (o complementarias), y funcionarían sus estados $+$ y $-$ como un *exclusive or*, no se deben aumentar ambas.

3.6. Diagrama de Interacción Triple

Aunque no se requiere esta gráfica en el desarrollo del parcial, se adjunta, en la figura 10, el diagrama de interacción triple para las variables más significativas del sistema.




Figura 10: Diagrama de interacción triple para RI, OI y OE.

Un diagrama de interacción triple en el contexto de diseño de experimentos se utiliza para visualizar las interacciones entre tres variables independientes en un experimento. Cada arista del cubo representa una tripla (OI, OE, RI), y el número en azul es el tiempo en el sistema promediado del resto de combinaciones para esta tripla con valores fijos.

3.7. Breve Análisis

Aunque las interpretaciones de las gráficas y resultados se han presetado en cada subsección, a continuación se plasman unas conclusiones generales.

1. Las variables más influyentes en el tiempo del sistema de forma individual son OI, OE, y RI.
2. Las variables que más interactúan entre sí son OI y OE, porque en la simulación tienen el mismo rol. El resto interactúan poco o nada.
3. Conforme se tuplas mas grandes de las variables en consideración, la normalidad en las medias del tiempo en el sistema de va perdiendo. Esto sucede porque se deja casi ningún grado de libertad y el sistema queda degenerado.
4. Con respecto al objetivo secundario de maximizar el porcentaje de ocupación de los operarios, mediante observación y filtrado en Excel fue fácil determinar que las combinaciones que permiten mayor eficiencia (alrededor del 80 %) son aquellas que dejan que aumentan el número de réplicas sin aumentar el número de empleados (de esperarse porque están siempre más ocupados).
5. No obstante, cuando se mejora el tiempo en el sistema (que es muy notable cuando se aumenta OI, OE y RI), la eficiencia puede caer hasta el 40 %, por lo que se aprecia el dilema de la optimización multiobjetivo.
6. Al igual que se concluye con los otros dos métodos, si la empresa puede invertir en ampliar su capacidad debe hacerlo en este orden jerárquico:

RI, OI, OE, R4K, RSTV, RLED

Pero se recomienda aumentar RI, OI y R4K porque aumentar los dos tipos de operarios lleva a una mucha mayor ineficiencia en los emmpleados.

4. Optimización de la Simulación

4.1. Variables de decisión y sus rangos

Para lograr los objetivos planteados al inicio del trabajo se seleccionaron seis variables de decisión. Entre ellas se encuentran los empleados disponibles y la cantidad de máquinas de ensamblaje y de inspección. Se decidió que los rangos tuvieran más ampliación que los originales para ver si los resultados esperados dependían de la cantidad de personas y maquinaria que están en la planta. En este sentido, se presentan los valores asignados a continuación.

	Select	Variable Name	Lower Bound	Suggested Value	Upper Bound	Type
	<input checked="" type="checkbox"/>	Op_Inspección.Number Available	1	0	4	Discrete (1)
	<input type="checkbox"/>	Técnicos_reparación.Number Available	0	0	1000	Discrete (1)
	<input checked="" type="checkbox"/>	EnsamblajeLEDReplication.Content	1	0	4	Discrete (1)
	<input checked="" type="checkbox"/>	Ensamblaje4KReplication.Content	1	0	4	Discrete (1)
	<input checked="" type="checkbox"/>	EnsamblajeSmartTVReplication.Content	1	0	4	Discrete (1)
	<input checked="" type="checkbox"/>	Op_Ensamble.Number Available	1	0	3	Discrete (1)
	<input type="checkbox"/>	T_Sistema.Content	0	0	1000	Discrete (1)
	<input type="checkbox"/>	Occupation_Ensamblaje.Content	0	0	1000	Discrete (1)
	<input type="checkbox"/>	Occupation_Inspection.Content	0	0	1000	Discrete (1)
	<input type="checkbox"/>	Occupation_Tecnico.Content	0	0	1000	Discrete (1)
	<input type="checkbox"/>	Max_TSistema.Content	0	0	1000	Discrete (1)
	<input checked="" type="checkbox"/>	InspecciónReplication.Content	1	0	4	Discrete (1)

Figura 11: Variables de decisión OptQuest

4.2. Función objetivo y restricciones

Para el cumplimiento de los objetivos no se plantean restricciones, dado que aquellas tienen relación, principalmente, con los tiempos en el sistema y el porcentaje de ocupación de los empleados. Estos últimos al ser resultados del modelo, no pueden simbolizarse mediante variables de decisión puesto que si esto llegara a ocurrir, el software asignaría números aleatorios a factores que en realidad son resultados que ocurren durante la simulación; así pues, no se generarían resultados coherentes. Por otro lado, con la función objetivo se busca minimizar el promedio del tiempo en el sistema.

	Select	Name
	No	Productos terminados.Average Time in System (3)
	No	Productos terminados.Maximum Time in System (3)
	No	Op_Ensamble.Utilization %
	No	Op_Inspección.Utilization %
	No	Técnicos_reparación.Utilization %
	No	PoolReplication.Value
	No	Productos terminados.Maximum Time in System
	Minimize Objective	Productos terminados.Average Time in System

Figura 12: Función objetivo del OptQuest

4.3. Resultados del OptQuest

Para construir los resultados en el software, se estipula la siguiente cantidad de simulaciones.

The screenshot shows the 'Time' tab of the OptQuest interface. It contains three radio buttons for running simulations: 'Run for' (selected), 'Run for' (minutes), and 'Run until'. The 'Run for' option is set to 50 simulations. Below these options, the 'Current Time and Date' is displayed as 9:43:56 AM on May 14, 2024.

Figura 13: Cantidad de corridas de OptQuest.

Al igual que lo experimentado con anterioridad, se ve que a pesar de que los tiempos en el sistema mejoren, lo único que no se cumple de los objetivos propuestos es el porcentaje de ocupación. Esto podría deberse a que la demanda de la planta no es tan grande como para requerir de una gran ocupación de operarios y de maquinaria. Asimismo, puede intervenir el hecho de que se necesita que los productos tengan un menor tiempo en el sistema; por consiguiente, los trabajadores no requieren de mucha ocupación.

La solución arrojada por el software indica que la empresa debería contratar más personal y disponer de un mayor número de máquinas para obtener los propósitos planteados.




Figura 14: Resultado de la Optimización

5. Análisis general

En primer lugar, la evaluación de alternativas probando escenarios diferentes, manualmente, es una estrategia poco eficiente porque toma bastante tiempo analizar qué factores se deben cambiar para lograr los objetivos. Además, no hay garantía de que la solución óptima se encuentre entre los escenarios considerados.

El método 2^k permite realizar análisis estadísticos más profundos que los otros dos métodos. Lo cual, puede conceder una ventaja al momento de comprender la situación que se está trabajando. Por ejemplo, a diferencia de los otros métodos permite entender como las modificaciones de la variables inciden, no solo sobre el objetivo, sino sobre las demás variables que se están analizando. Además, es un método bastante robusto. Sin embargo, es un método computacionalmente costoso porque se deben realizar todas las combinaciones, aun así no hayan cambios en los resultados. También, se debe conocer bien el sistema para saber qué valores de los recursos se van analizar porque si hay algún error, se debe realizar todo el proceso de nuevo. Asimismo, las gráficas se pueden volver muy complejas y difíciles de analizar.

Por su parte, el OptQuest es una herramienta que resuelve estos problemas de eficiencia, dado que permite probar múltiples combinaciones de diversos factores de manera simultánea. Asimismo, este método se lleva a cabo de una manera más amigable, dado que la interfaz facilita mucho más el proceso de digitar las restricciones, la función objetivo y los rangos de las variables de decisión. En este sentido, es una herramienta que nos ayuda a encontrar la respuesta a nuestro problema de una forma más eficaz.

Finalmente, dependiendo de la complejidad y las necesidades del problema se puede escoger un método u otro. Todos cuentan con sus ventajas pero, son beneficios que se reflejan si nos ubicamos en el contexto adecuado.